

# **Trabalho Prático - Gato vs Não-Gato**

**INE5430 - Inteligência Artificial**

**Grupo:**

- Bruno da Silva Castilho
- Gabriel Dutra

## **1. Introdução**

O presente relatório descreve o processo e os resultados obtidos no trabalho de classificação de imagens de gatos e não gatos utilizando regressão logística e uma rede de camada rasa.

## **2. Dados de Entrada**

Os dados utilizados neste trabalho foram obtidos a partir de uma base fornecida no curso de deep learning do Andrew Ng. O conjunto de dados consiste em imagens RGB de tamanho 64x64x3, onde cada imagem é representada como uma matriz de 64x64 pixels coloridos.

## **3. Regressão Logística**

**Casos de Teste:**


- **Teste-1:** Utilizando 10 imagens do conjunto de testes.
- **Teste-2:** Utilizando 80 imagens do conjunto de testes.
- **Teste-3:** Utilizando 209 imagens do conjunto de testes.

**Resultados:**

**Teste-1:**

- **Taxa de Acerto:** 66%

- Matriz de Confusão:




- Relatório de Classificação:

	precision	recal	f1-score	supporte
cat	0.5	0.82	0.62	17
noncat	0.86	0.58	0.69	33
accuracy			0.66	50
macro avg	0.68	0.7	0.66	50
weighted avg	0.74	0.66	0.67	50

Teste-2:

- Taxa de Acerto: 56%
- Matriz de Confusão:




- Relatório de Classificação:

	precision	recal	f1-score	supporte
cat	0.43	0.88	0.58	17
noncat	0.87	0.39	0.54	33
accuracy			0.56	50
macro avg	0.65	0.64	0.56	50
weighted avg	0.72	0.56	0.55	50

Teste-3:

- Taxa de Acerto: 70%
- Matriz de Confusão:



- Relatório de Classificação:

	precision	recal	fl-score	supporte
cat	0.55	0.71	0.62	17
noncat	0.82	0.70	0.75	33
accuracy			0.70	50
macro avg	0.68	0.70	0.68	50
weighted avg	0.73	0.70	0.71	50

## 4. Rede de camada rasa

### Casos de Teste:

#### Teste-1:

- **Camada de entrada:** 64x64x3 vetores.
- **Camada intermediária:** 100 neurônios com função de ativação sigmoid.
- **Camada de saída:** 1 neurônio com função de ativação sigmoid.

#### Teste-2:

- **Camada de entrada:** 64x64x3 vetores.
- **Camada intermediária:** 200 neurônios com função de ativação sigmoid.
- **Camada de saída:** 1 neurônio com função de ativação sigmoid.

#### Teste-3:

- **Camada de entrada:** 64x64x3 vetores.
- **Camada intermediária:** 100 neurônios com função de ativação ReLU.
- **Camada de saída:** 1 neurônio com função de ativação sigmoid.

#### Teste-4:


- **Camada de entrada:** 64x64x3 vetores.
- **Camada intermediária:** 200 neurônios com função de ativação ReLU.
- **Camada de saída:** 1 neurônio com função de ativação sigmoid.

### Resultados:

#### Teste-1:

- **Taxa de Acerto:** 34%

- Matriz de Confusão:




- Relatório de Classificação:

	precision	recal	f1-score	supporte
cat	0.34	1	0.51	17
noncat	0	0	0	33
accuracy			0.34	50
macro avg	0.17	0.50	0.25	50
weighted avg	0.12	0.34	0.17	50

Teste-2:

- Taxa de Acerto: 80%

- Matriz de Confusão:




- Relatório de Classificação:

	precision	recal	f1-score	supporte
cat	0.7	0.71	0.71	17
noncat	0.85	0.85	0.85	33
accuracy			0.80	50
macro avg	0.78	0.78	0.78	50
weighted avg	0.80	0.80	0.80	50

Teste-3:

- Taxa de Acerto: 72%

- Matriz de Confusão:




- Relatório de Classificação:

	precision	recal	f1-score	supporte
cat	0.56	0.88	0.68	17
noncat	0.91	0.64	0.75	33
accuracy			0.72	50
macro avg	0.73	0.76	0.72	50
weighted avg	0.79	0.72	0.73	50

Teste-4:

- Taxa de Acerto: 58%
- Matriz de Confusão:





● Relatório de Classificação:

	precision	recal	f1-score	supporte
cat	0.62	0.76	0.68	17
noncat	0.86	0.76	0.81	33
accuracy			0.76	50
macro avg	0.74	0.76	0.75	50
weighted avg	0.78	0.76	0.76	50

## 5. Conclusão

Os resultados obtidos revelam que a regressão logística, apesar de simples, apresentou desempenho moderado na classificação de imagens de gatos e não gatos. O modelo conseguiu atingir taxas de acerto que variaram de 56% a 70% nos diferentes testes realizados. Observou-se que o aumento no número de imagens de treinamento melhorou a precisão do modelo.

Por outro lado, a rede de camada rasa apresentou desempenho variado conforme a configuração das camadas intermediárias e funções de ativação utilizadas. Configurações mais complexas, como aquelas utilizando funções de ativação ReLU e um maior número de neurônios na camada intermediária, geralmente mostraram melhorias na taxa de acerto em comparação com configurações mais simples utilizando a função sigmoid.

Em resumo, embora ambos os métodos, regressão logística e redes neurais de camada rasa, tenham demonstrado a capacidade de aprender a distinguir entre imagens de gatos e não gatos, a escolha do método depende da complexidade dos dados e dos requisitos de precisão do problema em questão. Redes neurais com arquiteturas mais complexas tendem a oferecer melhor desempenho, mas com o custo de maior demanda computacional e necessidade de mais dados para treinamento eficaz. A regressão logística, por outro lado, é mais simples e menos exigente em termos de recursos, mas pode não capturar tão bem as nuances dos dados de imagem complexos.